

共享单车需求预测与调度分析

计划融合 Capital Bikeshare 官方骑行记录与 Open-Meteo 历史天气数据，完成多源数据挖掘、需求预测、站点调度分析和可视化系统开发。

团队规模

4 人

计划周期

5 周

项目类型

选项 A + C

交付形式

代码 + 报告 +

Dashboard

团队成员：任泓臻 (2351458)、虞澍 (2352979)、黄彦炜 (2353117)、马小龙 (2353814)

1. 选题背景与意义

共享单车是城市短途出行的重要组成部分。实际运营中，车辆需求会受到通勤高峰、工作日与周末、天气变化、会员结构、车辆类型和区域功能差异等因素影响，常见问题包括热门站点无车可借、通勤终点车辆堆积、恶劣天气下需求波动明显等。

本项目计划以 Capital Bikeshare 公开骑行记录为主要数据源，并融合 Open-Meteo 历史天气数据，构建一个从数据采集、清洗融合、特征工程、多模型预测到站点调度分析和可视化展示的完整数据挖掘流程。

2. 研究问题与项目目标

项目目标：预测未来小时级骑行需求，识别站点净流出/净流入模式，并将结果转化为可解释的补车和清车建议。

- 小时级共享单车需求是否存在稳定的日周期、周周期和季节差异？
- 天气变量、会员类型和车辆类型是否能增强需求预测效果？
- 传统机器学习模型、集成树模型和 LSTM 时序模型在该任务中的表现有何差异？
- 如何基于站点净流入/净流出识别需要补车或清车的重点站点？

3. 数据来源与计划范围

数据类型	数据来源	计划字段	主要用途
骑行记录	Capital Bikeshare System Data	起止时间、起终点站、车辆类型、会员类型、经纬度	构建小时级需求和站点级净需求
历史天气	Open-Meteo Historical Weather API	温度、相对湿度、降水、风速	分析天气对骑行需求的影响
时间特征	由骑行开始时间派生	小时、星期、月份、周末、周期编码	捕捉通勤和周期规律

计划使用 2023-2025 三年骑行记录。若本地计算或下载压力较大，可先运行单年或单月烟测；正式实验统一聚合到小时粒度。

4. 技术路线

阶段	计划方法	计划输出
数据采集	下载月度 zip，调用 Open-Meteo API	原始骑行数据、小时级天气表
数据清洗	解析时间戳、过滤异常骑行时长、处理缺失站点	清洗后的骑行记录
数据融合	按开始时间聚合到小时，并按 timestamp 合并天气	hourly_demand.csv
特征工程	构造时间、周期、节假日、天气、会员比例、车辆类型比例、滞后和滚动均值特征	model_features.csv
模型训练	按时间顺序切分训练集和测试集，避免时间泄漏	模型文件、预测结果
站点增强	计算站点净流出/净流入、站点聚类 and Top 20 站点净需求预测	dispatch_recommendations.csv、station_clusters.csv、station_model_metrics.csv
系统展示	使用 Streamlit 和 Plotly 构建交互式 Dashboard	可运行演示系统

5. 模型与实验设计

模型类别	模型	设置目的
时间基线	Seasonal Naive	判断模型是否超过简单周期复制策略
线性模型	Ridge Regression	检查基础特征的线性解释能力
集成树模型	Random Forest、HistGradientBoosting、XGBoost	捕捉非线性关系和特征交互
深度时序模型	LSTM	对比序列建模方法在该任务中的适用性

实验计划采用时间顺序切分：前 80% 时间段作为训练集，后 20% 时间段作为测试集。LSTM 部分计划优先检测 GPU 环境；如果 CUDA 可用，则使用 GPU 训练，否则自动退回 CPU。

6. Dashboard 设计

页面	展示内容
数据概览	数据量、时间范围、天气分布、骑行趋势
需求预测	选择模型，查看真实值与预测值曲线
模型对比	指标表、误差分布、特征重要性
站点调度	Top 站点净流出/净流入、补车和清车建议、站点聚类、站点级预测
项目说明	数据来源、技术流程、分工、运行命令

7. 团队分工与进度计划

成员	学号	主要职责	周次	主要任务	阶段交付物
任泓臻	2351458	数据下载、清洗、天气融合、质量检查	第 1 周	选题和数据源确认	项目计划书
虞澍	2352979	特征工程、传统模型、XGBoost、实验脚本	第 2 周	数据管道	处理后数据
黄彦炜	2353117	LSTM、GPU/CPU 训练适配、深度模型解释	第 3 周	节假日特征和模型实验	指标和预测
马小龙	2353814	Dashboard、调度建议、图表导出、文档	第 4 周	站点聚类、Top 20 站点预测和系统展示	Dashboard
			第 5 周	报告答辩	报告、PPT、海报

8. 风险与应对

风险	可能影响	应对策略
数据下载或 API 不稳定	无法及时获取全部原始数据	缓存原始 zip 和处理后 CSV，支持复用已有数据
字段或时间格式不一致	清洗流程失败或样本丢失	编写字段检查和时间解析测试，必要时按月份兼容处理
全年数据处理较慢	训练和演示耗时过长	先完成半年版本，再扩展全年；Dashboard 读取离线结果
LSTM 效果不如集成树模型	深度模型贡献不明显	将其定位为对照实验，分析任务特征与模型适配性
现场演示环境波动	Dashboard 无法稳定启动	准备静态 HTML 图表、截图和演示视频作为备份

9. 验收标准与预期成果

1. 数据管道可以从原始骑行数据和天气 API 生成小时级建模表。
2. 至少完成 5 类模型对比，并输出统一格式的指标和预测文件。
3. 调度分析能够输出站点净流出/净流入排序、站点聚类画像、Top 20 站点预测和补车/清车建议。
4. Streamlit Dashboard 可以在本地启动，并加载全部核心图表。
5. 每名组员都有明确代码模块、文档章节或实验产出。

参考资料：Capital Bikeshare System Data、Open-Meteo Historical Weather API、Streamlit、Scikit-learn、PyTorch。