

项目主题：跨领域数据挖掘竞赛 ——从数据到决策的全流程实战

维度	说明
团队规模	4 人/组（固定）
项目周期	5 周
难度级别	中高（相当于小型科研课题或 Kaggle 竞赛）
核心要求	每个组员有明确的技术分工，项目需包含多个数据源融合、多种算法系统性对比、可交互的成果展示

一、项目选项（三选一）

选项 A：多源数据融合挖掘

整合至少 2 个不同来源/模态的数据集进行分析。

– 示例选题：

- 房价预测：结构化数据（房屋特征）+ 非结构化数据（房源描述文本/图片）
- 信用风险评估：用户基本信息 + 交易流水时序 + 社交媒体行为
- 城市犯罪预测：历史犯罪记录 + 人口统计数据 + POI 数据 + 天气数据

选项 B：算法系统性对比研究

针对同一任务，实现并对比至少 5 种不同类型的算法，进行深入的理论和实验分析。

– 示例选题：

- 异常检测算法全面对比：统计方法、隔离森林、LOF、One-Class SVM、自编码器
- 时间序列预测方法对比：ARIMA、Prophet、LSTM、Transformer、XGBoost（特征工程版）

选项 C：端到端应用系统开发

构建一个完整的数据挖掘应用，包含数据处理、模型训练、评估和轻量级交互界面。

– 示例选题：

- 电影推荐系统：协同过滤 + 基于内容的推荐 + 冷启动处理 + Streamlit 演示界面
- 股票情绪分析：新闻/社交媒体爬取 + NLP 情感分析 + 股价关联分析 + Dashboard

二、团队角色与分工

每位组员承担一个明确的技术角色，在报告中用贡献表说明，下表可供参考

角色	职责	可考核的输出
数据工程负责人	数据获取、清洗、融合、特征工程、数据管道构建	数据预处理代码、特征文档、数据血缘图
算法负责人（建模）	核心算法实现/调优、对比实验设计、超参数优化	模型训练代码、实验记录表、模型对比分析
评估与分析负责人	评估指标设计、统计显著性检验、结果可视化、错误分析	评估代码、可视化图表、分析报告章节
工程与交付负责人	代码整合、Pipeline 构建、交互界面/报告生成、版本管理	可运行完整代码、README、演示视频/PPT

额外要求：

- * 每个角色的贡献在报告中要有可量化的证据（如：某段代码的 commit 记录、某章节的作者署名）
- * 鼓励跨角色协作，但主责分明

三、项目交付物

序号	交付物	要求	团队分值占比
1	项目计划书	选题背景、数据来源、分工计划、时间表（第 13 周前提交）	5%
2	代码仓库	GitHub/Gitee 仓库，完整 commit 历史，每个组员有贡献记录	10%
3	完整代码	模块化、有注释、可一键运行主流程	25%
4	项目报告	10-20 页，学术论文格式，包含摘要、引言、方法、实验、讨论、结论	30%
5	团队分工声明	逐条说明每个人完成的具体代码文件、报告章节、工作量百分比	5%
6	答辩 PPT + 演示视频（可选）	10 分钟（讲解 + 系统演示/结果展示）	25%
7	项目海报（加分项）	A0/A1 尺寸，适合学术展示日	

Tips:

这个项目的设计目标是模拟真实的数据科学团队工作。在业界，你不会一个人完成所有事，但你需要：

- 在自己的领域成为专家
- 与队友高效协作
- 对最终结果负责